



CAHIER DES CHARGES

PHASE 1 : Moteur d'extraction intelligente (OCR) pour les plans techniques eDoc

PFA Oussama TABAKH | Encadrant : M. Mohamed Boumenzeh | Version 1.0

1. Contexte et objectif

eDoc gère le dépôt et l'indexation des plans techniques de chantier. Les métadonnées associées à chaque plan — **PHASE, EMETTEUR, LOT, TYPE, ZONE, NIVEAU, NUMERO, Titre1** (+ Indice, Titre2/Titre3 en optionnel) — sont aujourd'hui saisies manuellement à partir du cartouche du document.

Objectif : automatiser cette saisie via un pipeline d'extraction (OCR + LLM) exposé par API REST, avec un score de confiance par champ permettant de distinguer les extractions fiables de celles nécessitant une revue humaine.

2. Périmètre

Le sujet couvre l'extraction (texte **et** éléments graphiques), la structuration, l'exposition API **et** l'intégration dans les formulaires eDoc, portée conjointement avec Bakhi Adnane. Ce document détaille la Phase 1 ; la Phase 2 reste **dans le périmètre du stage** et sera cadrée à la suite elle n'est pas exclue.

Phase 1 moteur d'extraction (ce cycle)	Phase 2 à enchaîner	Hors périmètre du stage
Routage PDF/DOCX/XLSX ; isolation page 1		Pages autres que la page 1
Localisation cartouche — page de garde / plan dense	Intégration des résultats dans les formulaires eDoc (Angular/Java)	Fine-tuning de modèles
Cascade texte : natif → Tesseract → Mistral vision → Azure DI → revue humaine	Contrat API final eDoc	Dédoublonnage automatique du corpus
Structuration schéma Bordereau, matching flou, normalisation		Multi-cartouches par document
Score de confiance + statut ; API REST asynchrone + harnais d'évaluation		

3. Architecture retenue

Cascade avec repli automatique (plutôt qu'un outil unique) : aucun outil pris isolément ne couvre de façon fiable l'hétérogénéité du corpus constatée en analyse préalable, et les niveaux payants (Mistral, Azure) ne sont engagés que si les niveaux gratuits (natif, Tesseract) échouent. Escalade **par champ**, exécutée par appel groupé par outil (coût facturé à l'appel, pas au champ). Aucune valeur métier en dur : seuils, ordre de cascade et dictionnaire d'ancres sont externalisés en configuration.

Pile : Python (FastAPI, PyMuPDF, pdfplumber, RapidFuzz), Tesseract local, API Mistral vision, Azure Document Intelligence.

4. Contraintes

- **Confidentialité** : Azure DI et Mistral sont des services cloud tiers transmission de documents de chantier hors du SI interne.
- **Sécurité** : clés API en variables d'environnement uniquement, jamais en dur ni versionnées.
- **Technique** : page 1 uniquement, correction d'orientation systématique avant toute localisation.

5. Livrables

Livrable	Description	Critère d'acceptation
Prototype	Pipeline document → JSON Bordereau via API REST	8 champs + statuts de confiance en sortie
Rapport d'architecture	Cascade vs outils seuls, chiffres à l'appui	Chaque décision adossée à une mesure sur dataset
Démonstration	Scénario reproductible	1 document de chaque famille, résultat en direct

6. Points nécessitant la validation de l'encadrant

Q1 — Zéros de tête du champ NUMERO. Convention canonique à figer (« 085 » vs « 000439 ») avant tout calibrage des métriques.

Q2 — Mappings de libellés en hypothèse. Spécialité/Discipline→LOT, Localisation→ZONE, DOC→TYPE (cartouches Abidjan/Grand Paris) valides sur tout le périmètre ou spécifiques à ces projets ?

Q3 — Provisioning des clés API. Circuit à suivre (IT interne vs comptes tier gratuit) pour Azure DI et Mistral.

Q4 — Validation du principe de cascade. est-ce que ce principe de cascade convient, ou faut-il d'abord évaluer chaque outil indépendamment avant de trancher sur l'architecture ?

Q5 — Mistral : produit OCR dédié ou LLM vision généraliste ? Le sujet cite Mistral comme LLM spécialisé sans préciser lequel.